Tugas Besar IF2220 Probabilitas dan Statistika

Penarikan Kesimpulan dan Pengujian Hipotesis

Dibuat oleh :

- Lyora Felicya (13520073)
- Claudia (13520076)

In [ ]:

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import t, f, norm
from IPython.display import Markdown, display
from math import sqrt

print("Data water potability yang digunakan")
col_names = ["id", "pH", "Hardness", "Solids", "Chloramines", "Sulfate", "Conductivity", "OrganicCarbon", "Trihalomethanes", "Turbidity", "Potability"]
df = pd.read_csv("water_potability.csv", names = col_names)
df
```

```
Data water potability yang digunakan
```

Out[ ]:

	id	pH	Hardness	Solids	Chloramines	Sulfate	Conductivity	OrganicCarbon	Trihalomethanes	Turbidity	Potability
0	1	8.316766	214.373394	22018.417441	8.059332	356.886136	363.266516	18.436524	100.341674	4.628771	0
1	2	9.092223	181.101509	17978.986339	6.546600	310.135738	398.410813	11.558279	31.997993	4.075075	0
2	3	5.584087	188.313324	28748.687739	7.544869	326.678363	280.467916	8.399735	54.917862	2.559708	0
3	4	10.223862	248.071735	28749.716544	7.513408	393.663396	283.651634	13.789695	84.603556	2.672989	0
4	5	8.635849	203.361523	13672.091764	4.563009	303.309771	474.607645	12.363817	62.798309	4.401425	0
...	...	...	...	...	...	...	...	...	...	...	...
2005	2006	8.197353	203.105091	27701.794055	6.472914	328.886838	444.612724	14.250875	62.906205	3.361833	1
2006	2007	8.989900	215.047358	15921.412018	6.297312	312.931022	390.410231	9.899115	55.069304	4.613843	1
2007	2008	6.702547	207.321086	17246.920347	7.708117	304.510230	329.266002	16.217303	28.878601	3.442983	1
2008	2009	11.491011	94.812545	37188.826022	9.263166	258.930600	439.893618	16.172755	41.558501	4.369264	1
2009	2010	6.069616	186.659040	26138.780191	7.747547	345.700257	415.886955	12.067620	60.419921	3.669712	1

2010 rows × 11 columns

In [ ]:

```
print("Tipe data berupa integer atau float")
df.dtypes
```

```
Tipe data berupa integer atau float
```

Out[ ]:
```
id                   int64
pH                 float64
Hardness           float64
Solids             float64
Chloramines        float64
Sulfate            float64
Conductivity       float64
OrganicCarbon      float64
Trihalomethanes    float64
Turbidity          float64
Potability           int64
dtype: object
```

In [ ]:
```
print("Tidak ada data yang null")
df.isnull().sum()
```

Out[ ]:
```
Tidak ada data yang null
id                 0
pH                 0
Hardness           0
Solids             0
Chloramines        0
Sulfate            0
Conductivity       0
OrganicCarbon      0
Trihalomethanes    0
Turbidity          0
Potability         0
dtype: int64
```

Nomor 1

Menulis deskripsi statistika (Descriptive Statistics) dari semua kolom pada data yang bersifat numerik, terdiri dari mean, median, modus, standar deviasi, variansi, range, nilai minimum, maksimum, kuartil, IQR, skewness dan kurtosis. Boleh juga ditambahkan deskripsi lain.

In [ ]:
```
print("Berikut merupakan deskripsi statistika untuk semua kolom yang bersifat numerik")

describe_df = df.describe()

# Membuat dictionary
water = {}
water["Kolom"] = []
water["Mean"] = []
water["Median"] = []
water["Modus"] = []
water["Std"] = []
water["Var"] = []
water["Range"] = []
water["Min"] = []
water["Max"] = []
water["Q1"] = []
water["Q2"] = []
water["Q3"] = []
water["IQR"] = []
water["Skew"] = []
water["Kurtosis"] = []
```

```
for column in describe_df:
    water["Kolom"].append(column)
    water["Mean"].append(describe_df[column]["mean"])
    water["Median"].append(df.median()[column])
    water["Modus"].append(df.mode("index")[column][0])
    water["Std"].append(describe_df[column]["std"])
    water["Var"].append(df.var()[column])
    water["Range"].append(describe_df[column]["max"] - describe_df[column]["min"])
    water["Min"].append(describe_df[column]["min"])
    water["Max"].append(describe_df[column]["max"])
    water["Q1"].append(describe_df[column]["25%"])
    water["Q2"].append(describe_df[column]["50%"])
    water["Q3"].append(describe_df[column]["75%"])
    water["IQR"].append(describe_df[column]["75%"] - describe_df[column]["25%"])
    water["Skew"].append(df.skew()[column])
    water["Kurtosis"].append(df.kurtosis()[column])


dataframe_new = pd.DataFrame(water, index = [i for i in range(1,12)])
dataframe_new
```

```
Berikut merupakan deskripsi statistika untuk semua kolom yang bersifat numerik
```

Out[ ]:

	Kolom	Mean	Median	Modus	Std	Var	Range	Min	Max	Q1	Q2	Q3	IQR	Skew	Kurtosis
1	id	1005.500000	1005.500000	1.000000	580.381340	3.368425e+05	2009.000000	1.000000	2010.000000	503.250000	1005.500000	1507.750000	1004.500000	0.000000	-1.200000
2	pH	7.087193	7.029490	0.227499	1.572803	2.473709e+00	13.772501	0.227499	14.000000	6.090785	7.029490	8.053006	1.962221	0.048535	0.626904
3	Hardness	195.969209	197.203525	73.492234	32.643166	1.065576e+03	243.845890	73.492234	317.338124	176.740657	197.203525	216.447589	39.706932	-0.085321	0.525480
4	Solids	21904.673439	20926.882155	320.942611	8625.397911	7.439749e+07	56167.729801	320.942611	56488.672413	15614.412962	20926.882155	27170.534649	11556.121687	0.591011	0.337320
5	Chloramines	7.134322	7.142014	1.390871	1.585214	2.512904e+00	11.736129	1.390871	13.127000	6.138326	7.142014	8.109933	1.971607	0.013003	0.549782
6	Sulfate	333.211376	332.214113	129.000000	41.211111	1.698356e+03	352.030642	129.000000	481.030642	307.626986	332.214113	359.268147	51.641161	-0.045728	0.786854
7	Conductivity	426.476708	423.438372	201.619737	80.701872	6.512792e+03	551.722883	201.619737	753.342620	366.619219	423.438372	482.209772	115.590553	0.268012	-0.237206
8	OrganicCarbon	14.357940	14.323286	2.200000	3.325770	1.106075e+01	24.806707	2.200000	27.006707	12.122530	14.323286	16.683562	4.561031	-0.020220	0.031018
9	Trihalomethanes	66.400717	66.482041	8.577013	16.081109	2.586021e+02	115.422987	8.577013	124.000000	55.949993	66.482041	77.294613	21.344620	-0.051383	0.223017
10	Turbidity	3.969497	3.967374	1.450000	0.780471	6.091350e-01	5.044749	1.450000	6.494749	3.442882	3.967374	4.514663	1.071781	-0.032266	-0.049831
11	Potability	0.402985	0.000000	0.000000	0.490620	2.407079e-01	1.000000	0.000000	1.000000	0.000000	0.000000	1.000000	1.000000	0.395873	-1.845122

Nomor 2

Membuat Visualisasi plot distribusi, dalam bentuk histogram dan boxplot untuk setiap kolom numerik. Berikan uraian penjelasan kondisi setiap kolom berdasarkan kedua plot tersebut.

In [ ]:

```
sns.set_theme(style="whitegrid")
```

---

id

In [ ]:
```
df["id"].hist(bins = 30)
```
Out[ ]: `<AxesSubplot:>`

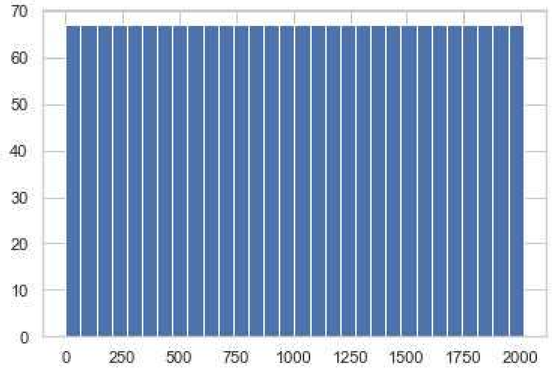

In [ ]:
```
sns.boxplot(x = df["id"])
```
Out[ ]: `<AxesSubplot:xlabel='id'>`

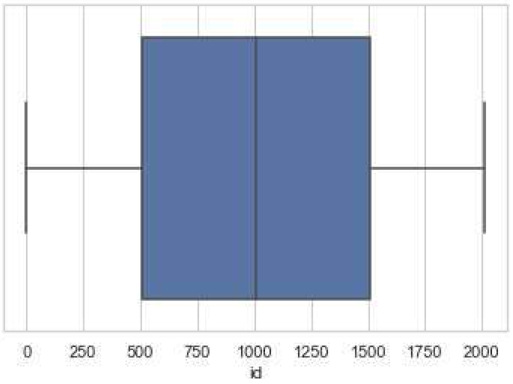

Distribusi data pada kolom id merupakan distribusi uniform. Hal ini dapat dilihat dari jarak antara maksimum, Q1, median, Q3, dan minimum yang sama rata. Data ini juga memiliki skew 0, sehingga nilai median dan rata-ratanya sama

---

pH

In [ ]:
```
df["pH"].hist(bins = 30)
```
Out[ ]: `<AxesSubplot:>`

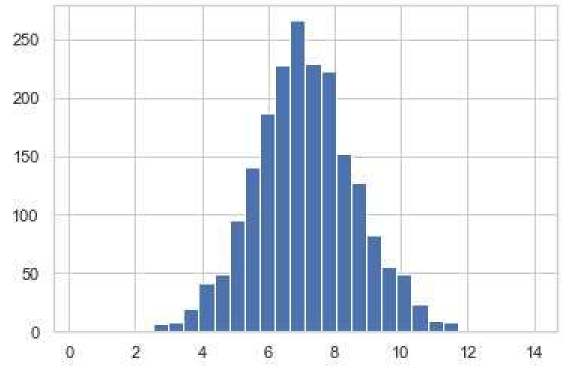


```
In [ ]: sns.boxplot(x = df["pH"])
```

```
Out[ ]: <AxesSubplot:xlabel='pH'>
```

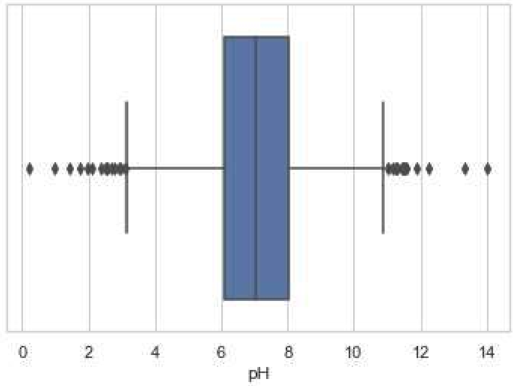

Distribusi data pada kolom pH ini terlihat normal. Pada boxplot, terlihat bahwa data ini memiliki pencilan pada kedua sisi. Hal ini sesuai dengan karakteristik data yang terdistribusi normal, yaitu umumnya memiliki 0.35% pencilan pada kedua sisinya. Pada histogram juga terlihat bahwa frekuensi datanya cenderung seimbang antara kiri dan kanan. Data kolom pH ini memiliki skew mendekati 0, karena median kurang lebih berada di tengah "minimum" dan "maksimum".

Hardness

```
In [ ]: df["Hardness"].hist(bins = 30)
```

```
Out[ ]: <AxesSubplot:>
```

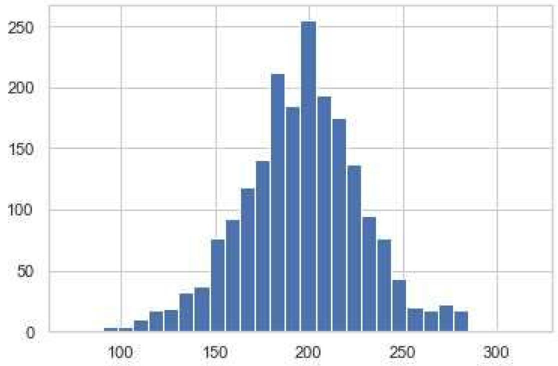

In [ ]:
```
sns.boxplot(x = df["Hardness"])
```

Out[ ]: `<AxesSubplot:xlabel='Hardness'>`

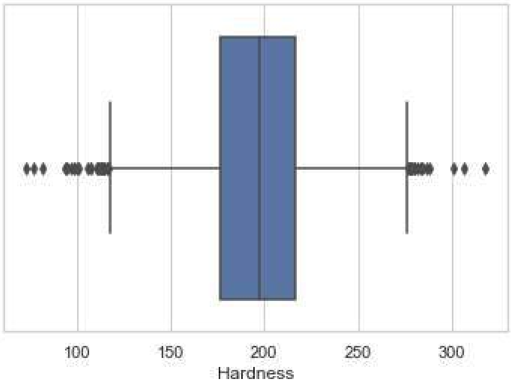

Distribusi data pada kolom Hardness ini terlihat menyerupai distribusi normal. Pada boxplot, terlihat bahwa data ini memiliki pencilan pada kedua sisi. Hal ini sesuai dengan karakteristik data yang terdistribusi normal, yaitu umumnya memiliki 0.35% pencilan pada kedua sisinya. Pada histogram juga terlihat bahwa frekuensi datanya cenderung seimbang antara kiri dan kanan. Data kolom Hardness ini memiliki skew mendekati 0, karena median kurang lebih berada di tengah "minimum" dan "maksimum".

Solids

In [ ]:
```
df["Solids"].hist(bins = 30)
```

Out[ ]: `<AxesSubplot:>`

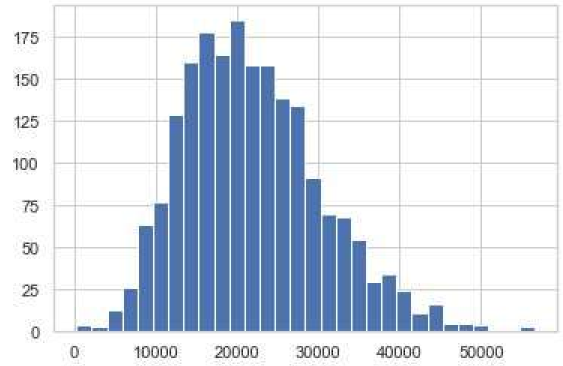

In [ ]:
```
sns.boxplot(x = df["Solids"])
```

Out[ ]: <AxesSubplot:xlabel='Solids'>

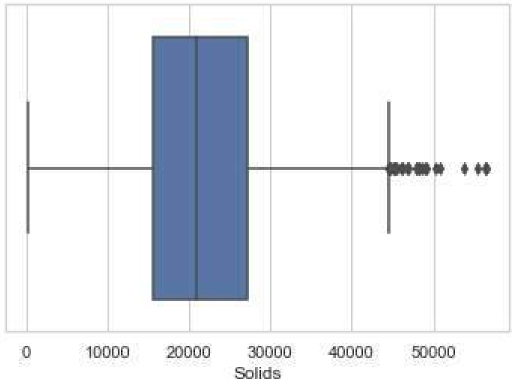

Distribusi data pada kolom Solids ini jauh dari distribusi normal, dan terlihat seperti distribusi half-normal terbalik. Hal ini terlihat dari boxplot, dimana nilai minimum data tidak sama dengan Q1 - 1.5*IQR, serta memiliki pencilan sangat banyak di atas nilai maksimum. Nilai median juga lebih dekat pada minimum, sehingga menggambarkan skew bernilai positif. Pada histogram juga terlihat frekuensi data lebih berat ke kiri.

Chloramines

In [ ]:
```
df["Chloramines"].hist(bins = 30)
```

Out[ ]: <AxesSubplot:>

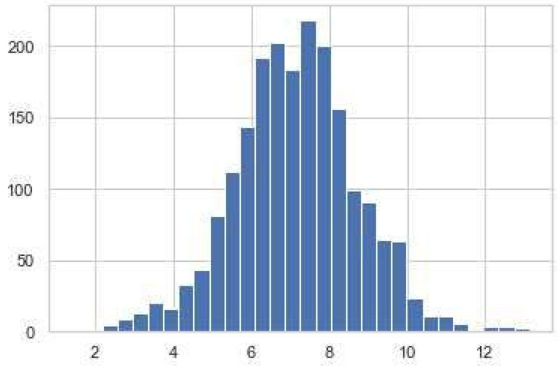

In [ ]:
```
sns.boxplot(x = df["Chloramines"])
```

Out[ ]: <AxesSubplot:xlabel='Chloramines'>

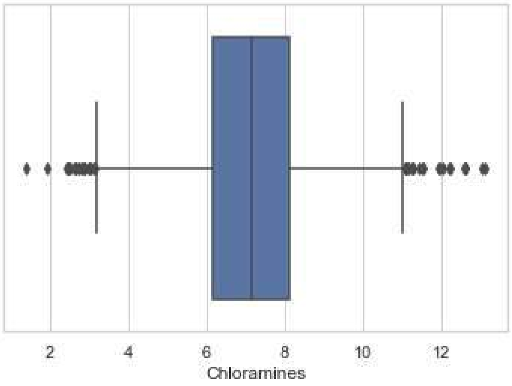

Distribusi data pada kolom Chloramines ini menyerupai distribusi normal. Pada boxplot, terlihat bahwa data ini memiliki pencilan pada kedua sisi. Pada histogram juga terlihat bahwa frekuensi datanya cenderung seimbang antara kiri dan kanan. Data kolom Chloramines ini memiliki skew mendekati 0, karena median kurang lebih berada di tengah "minimum" dan "maksimum".

Sulfate

In [ ]:
```
df["Sulfate"].hist(bins = 30)
```

Out[ ]: <AxesSubplot:>

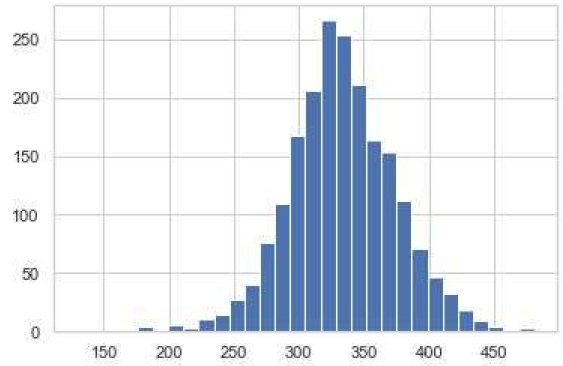

In [ ]:
```
sns.boxplot(x = df["Sulfate"])
```

Out[ ]: <AxesSubplot:xlabel='Sulfate'>

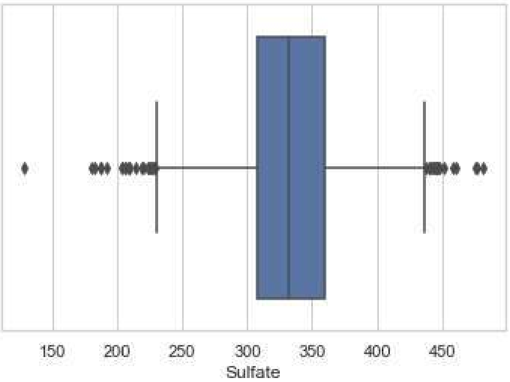

Distribusi data pada kolom Sulfate ini terlihat menyerupai distribusi normal. Pada boxplot, terlihat bahwa data ini memiliki pencilan pada kedua sisi, dan terdapat 1 buah pencilan yang bernilai sangat kecil (<150). Pada histogram juga terlihat bahwa datanya menyerupai distribusi normal, dimana frekuensi datanya cenderung seimbang antara kiri dan kanan.

Conductivity

In [ ]:
```
df["Conductivity"].hist(bins = 30)
```

Out[ ]: <AxesSubplot:>

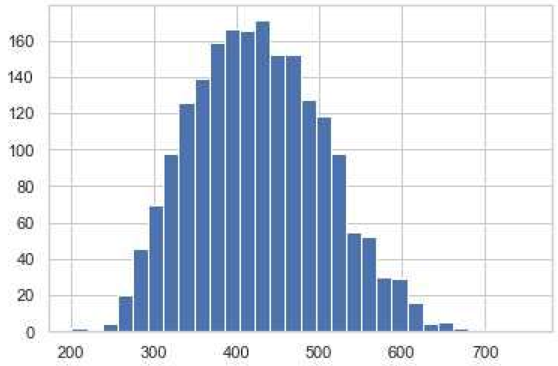

In [ ]:
```
sns.boxplot(x = df["Conductivity"])
```

Out[ ]:
```
<AxesSubplot:xlabel='Conductivity'>
```

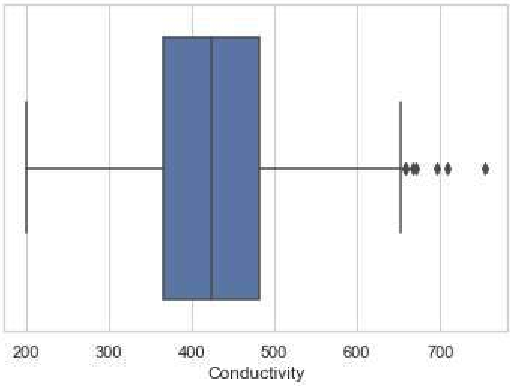

Distribusi data pada kolom Conductivity ini jauh dari distribusi normal, dan terlihat seperti distribusi half-normal terbalik. Hal ini terlihat dari boxplot, dimana nilai minimum data tidak sama dengan Q1 - 1.5*IQR, serta memiliki pencilan sangat banyak di atas nilai maksimum dan tidak terdapat pencilan di bawah nilai minimum. Nilai median juga lebih dekat pada minimum, sehingga menggambarkan skew bernilai positif. Pada histogram juga terlihat frekuensi data lebih berat ke kiri dan frekuensinya tidak seimbang antara kiri dan kanan.

OrganicCarbon

In [ ]:
```
df["OrganicCarbon"].hist(bins = 30)
```

Out[ ]:
```
<AxesSubplot:>
```

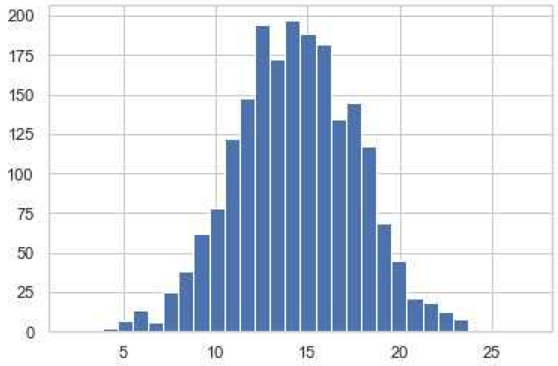

In [ ]:
```
sns.boxplot(x = df["OrganicCarbon"])
```

Out[ ]: `<AxesSubplot:xlabel='OrganicCarbon'>`

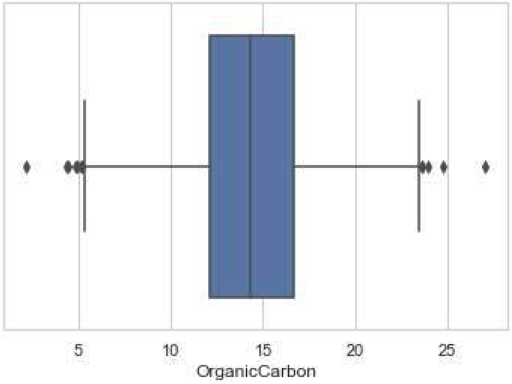

Distribusi data pada kolom OrganicCarbon ini dapat dikatakan sebagai distribusi normal. Pada boxplot, terlihat bahwa data ini memiliki pencilan pada kedua sisi. Hal ini sesuai dengan karakteristik data yang terdistribusi normal, yaitu umumnya memiliki 0.35% pencilan pada kedua sisinya. Pada histogram juga terlihat bahwa datanya menyerupai distribusi normal, dimana frekuensi datanya seimbang antara kiri dan kanan. Data kolom OrganicCarbon ini memiliki skew mendekati 0, karena median kurang lebih berada di tengah "minimum" dan "maksimum".

Trihalomethanes

In [ ]:
```
df["Trihalomethanes"].hist(bins = 30)
```

Out[ ]: `<AxesSubplot:>`

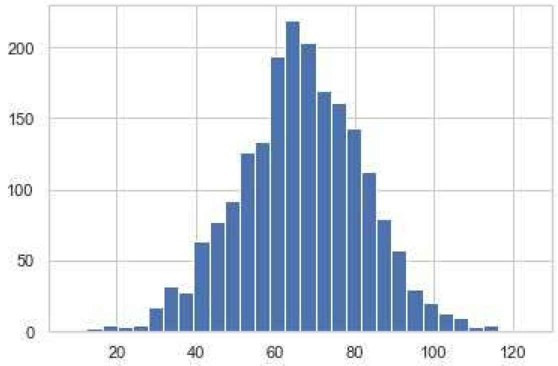

In [ ]:
```
sns.boxplot(x = df["Trihalomethanes"])
```

Out[ ]: <AxesSubplot:xlabel='Trihalomethanes'>

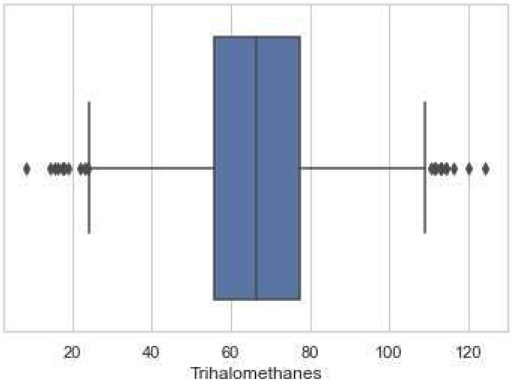

Distribusi data pada kolom Trihlomethanes ini dapat dikatakan sebagai distribusi normal. Pada boxplot, terlihat bahwa data ini memiliki pencilan pada kedua sisi. Hal ini sesuai dengan karakteristik data yang terdistribusi normal, yaitu umumnya memiliki 0.35% pencilan pada kedua sisinya. Pada histogram juga terlihat bahwa datanya menyerupai distribusi normal. Data kolom Trihalomethanes ini memiliki skew mendekati 0, karena median kurang lebih berada di tengah "minimum" dan "maksimum".

Turbidity

In [ ]:
```
df["Turbidity"].hist(bins = 30)
```

Out[ ]: <AxesSubplot:>

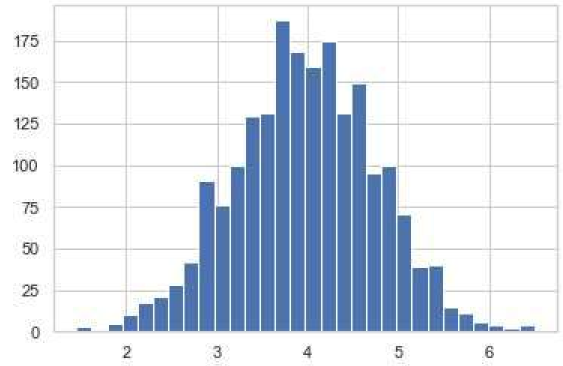

In [ ]:
```
sns.boxplot(x = df["Turbidity"])
```

Out[ ]: `<AxesSubplot:xlabel='Turbidity'>`

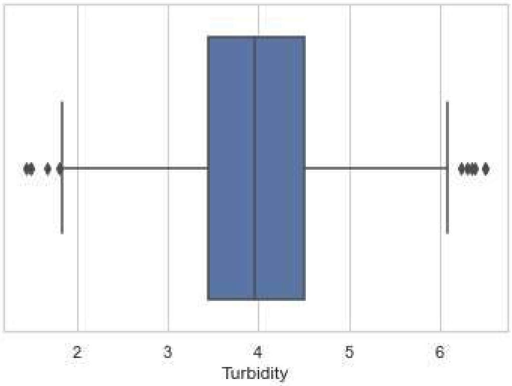

Distribusi data pada kolom Turbidity ini dapat dikatakan sebagai distribusi normal. Pada boxplot, terlihat bahwa data ini memiliki pencilan pada kedua sisi. Hal ini sesuai dengan karakteristik data yang terdistribusi normal, yaitu umumnya memiliki 0.35% pencilan pada kedua sisinya. Pada histogram juga terlihat bahwa datanya menyerupai distribusi normal, dimana frekuensi datanya seimbang antara kiri dan kanan. Data kolom Turbidity ini memiliki skew mendekati 0, karena median kurang lebih berada di tengah "minimum" dan "maksimum".

Potability

In [ ]:
```
df["Potability"].hist(bins = 30)
```

Out[ ]: `<AxesSubplot:>`

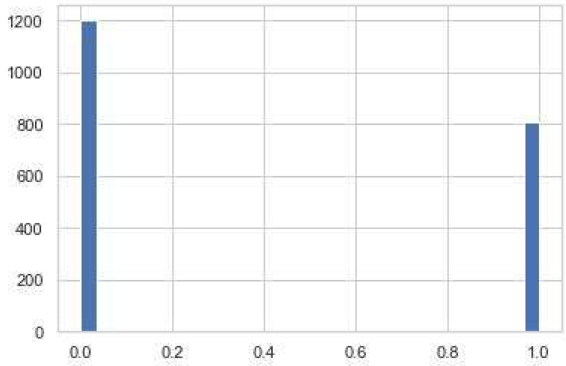

In [ ]:
```
sns.boxplot(x = df["Potability"])
```

Out[ ]:
```
<AxesSubplot:xlabel='Potability'>
```

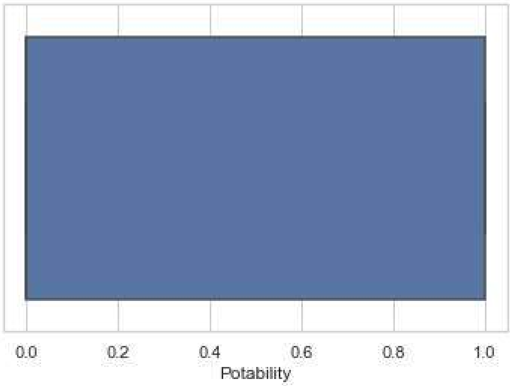

Data pada kolom Potability hanya terdiri atas 2 nilai, yaitu 0 atau 1.

Nomor 3

Menentukan setiap kolom numerik berdistribusi normal atau tidak. Gunakan normality test yang dikaitkan dengan histogram plot.

Penjelasan D'Agostino's and Pearson's Omnibus Test Of Normality

Normality test dilakukan dengan menggunakan fungsi `normaltest` dari library scipy dan akan divisualisaasikan dengan `seaborn.histplot()`. Apabila hasil tes menyimpulkan kolom berdistribusi normal, maka pada histogram plot akan tergambar bell-shaped curve (kurva simetris).

Tes D'Agostino-Pearson, atau disebut juga Omnibus D'Agostino, dilakukan dengan menggabungkan hasil tes skewness dan kurtosis D'Agostino. Rumusnya diberikan sebagai berikut:

$$K^2 = Z_s^2 + Z_k^2$$

Z_s merupakan hasil dari tes Skewness Agostino dan Z_k merupakan hasil tes Kurtosis Agostino. K^2 diaproksimasi terdistribusi secara χ^2 (chi-squared) dengan 2 degrees of freedom (derajat kebebasan 2).

Hipotesis null H_0 dalam test ini adalah data pada kolom tertentu terdistribusi secara normal. Apabila nilai $p > \alpha$, maka H_0 akan diterima, sehingga kolom dapat disimpulkan memiliki distribusi normal. Sebaliknya apabila nilai $p \leq \alpha$, maka H_0 ditolak, sehingga kolom yang bersangkutan dapat disimpulkan tidak memiliki distribusi normal.

Normality test dibawah ini akan menghasilkan dua buah output, yaitu nilai p-value yang didapat serta kesimpulan apakah hipotesis 0 diterima atau ditolak.

In [ ]:
```
from scipy import stats

def normalityTest(df):
    k2, p = stats.normaltest(df)
    print("P-value dari data ini adalah", p)
    if (p < 0.05):
        print("Karena p-value <= 0.05, maka Hipotesis nol ditolak. Data tidak terdistribusi normal.")
    else:
        print("Karena p-value > 0.05, maka Hipotesis nol diterima. Data terdistribusi normal.")
    sns.histplot(data = df, x = df, kde=True, stat="density", linewidth=0)
```

pH

In [ ]:
```
normalityTest(df["pH"])
```

```
P-value dari data ini adalah 2.6514813346797777e-05
Karena p-value <= 0.05, maka Hipotesis nol ditolak. Data tidak terdistribusi normal.
```

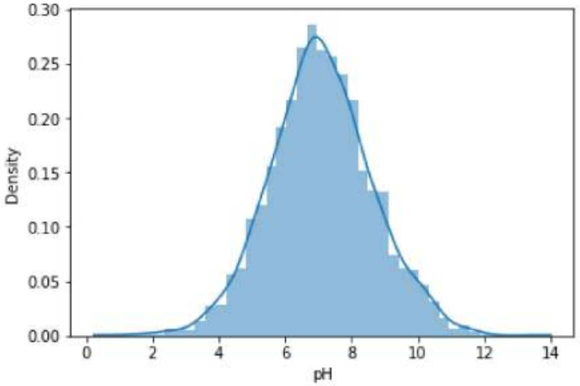

Hardness

In [ ]:
```
normalityTest(df["Hardness"])
```

```
P-value dari data ini adalah 0.00013442428699593753
Karena p-value <= 0.05, maka Hipotesis nol ditolak. Data tidak terdistribusi normal.
```

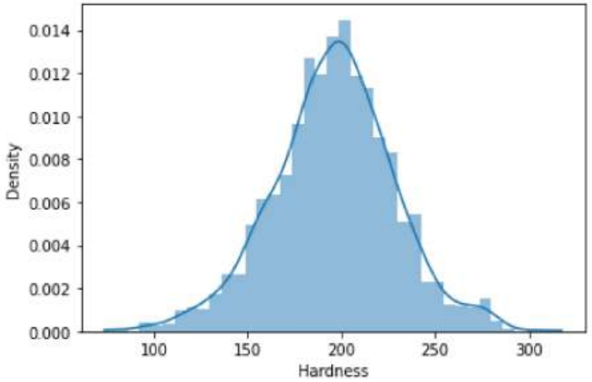

Solids

```
In [ ]: normalityTest(df["Solids"])
```

```
P-value dari data ini adalah 2.0796613688739523e-24
Karena p-value <= 0.05, maka Hipotesis nol ditolak. Data tidak terdistribusi normal.
```

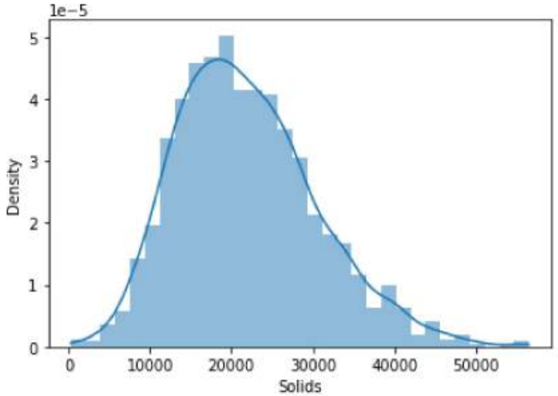

Chloramines

```
In [ ]: normalityTest(df["Chloramines"])
```

```
P-value dari data ini adalah 0.0002504831654753917
Karena p-value <= 0.05, maka Hipotesis nol ditolak. Data tidak terdistribusi normal.
```

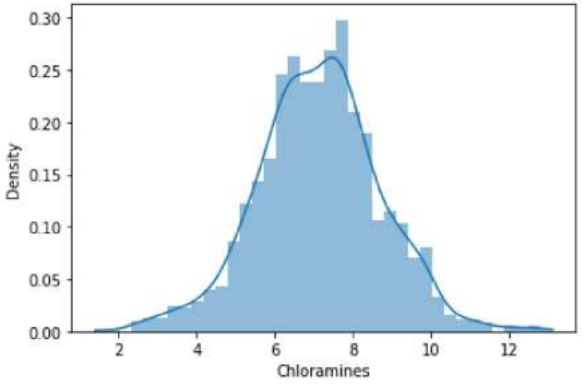

Sulfate

In [ ]:
```
normalityTest(df["Sulfate"])
```

```
P-value dari data ini adalah 4.4255936678013136e-07
Karena p-value <= 0.05, maka Hipotesis nol ditolak. Data tidak terdistribusi normal.
```

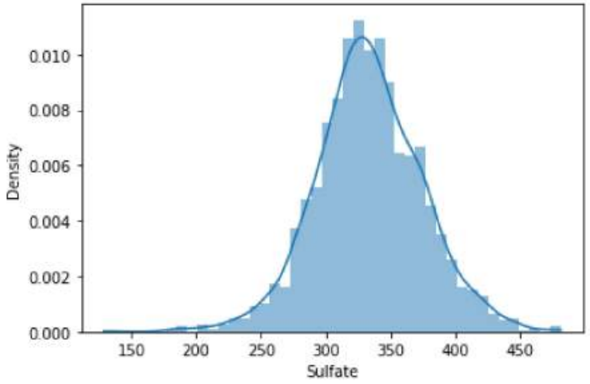

Conductivity

In [ ]:
```
normalityTest(df["Conductivity"])
```

```
P-value dari data ini adalah 4.39018078287845e-07
Karena p-value <= 0.05, maka Hipotesis nol ditolak. Data tidak terdistribusi normal.
```

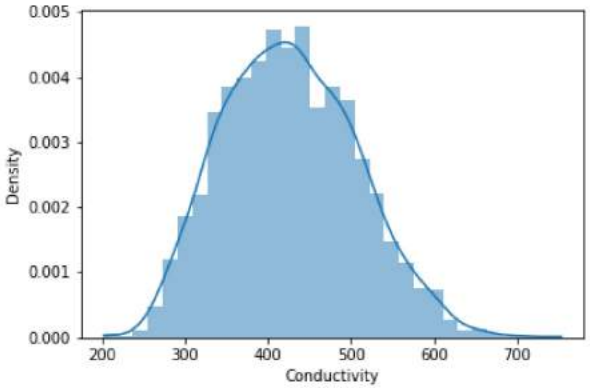

OrganicCarbon

In [ ]:
```
normalityTest(df["OrganicCarbon"])
```

```
P-value dari data ini adalah 0.8825496581408284
Karena p-value > 0.05, maka Hipotesis nol diterima. Data terdistribusi normal.
```

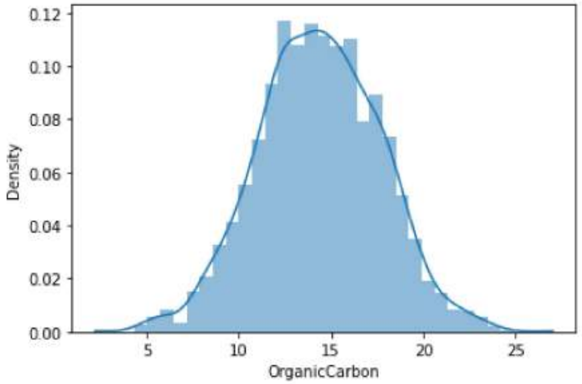

Trihalomethanes

In [ ]:
```
normalityTest(df["Trihalomethanes"])
```

```
P-value dari data ini adalah 0.1043598441875204
Karena p-value > 0.05, maka Hipotesis nol diterima. Data terdistribusi normal.
```

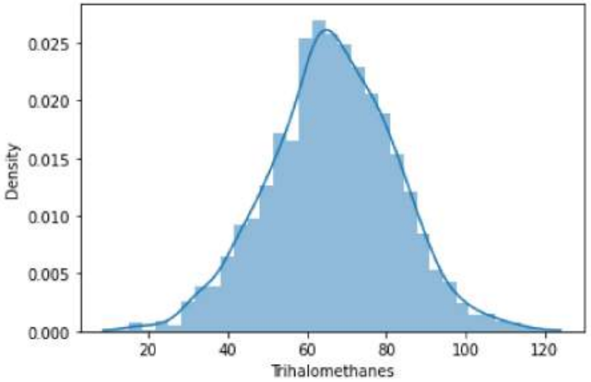

Turbidity

In [ ]:
```
normalityTest(df["Turbidity"])
```

```
P-value dari data ini adalah 0.7694717369961169
Karena p-value > 0.05, maka Hipotesis nol diterima. Data terdistribusi normal.
```

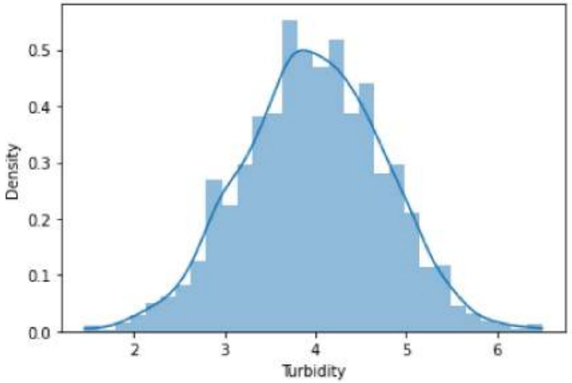

Portability

In [ ]:
```
normalityTest(df["Potability"])
```

```
P-value dari data ini adalah 0.0
Karena p-value <= 0.05, maka Hipotesis nol ditolak. Data tidak terdistribusi normal.
```

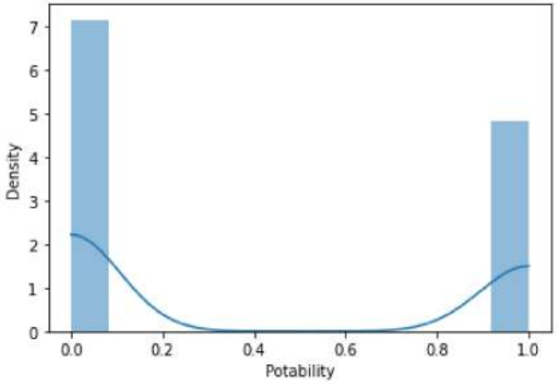

Nomor 4

Melakukan test hipotesis 1 sampel, dengan menuliskan 6 langkah testing dan menampilkan juga boxplotnya untuk kolom/bagian yang bersesuaian.

In [ ]:
```
import scipy.stats as st
```

---

a. Nilai Rata-rata pH di atas 7?

In [ ]:
```
ax = df.boxplot(["pH"])
ax.set_title("Boxplot pH")
plt.show()
```

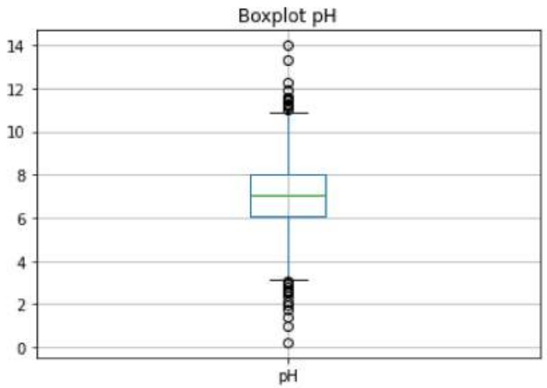

Langkah 1: Menentikan hipotesis nol H_0

$H_0 : \mu_{pH} = 7$

Hipotesis nol yaitu nilai rata-rata pH sama dengan 7

Langkah 2 : Menentukan hipotesis alternatif H_1

$H_1 : \mu_{pH} > 7$

Hipotesis alternatifnya yaitu nilai rata-rata pH lebih besar dari 7.

Langkah 3 : Menentukan Tingkat Signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4 : Penentuan uji statistik dan daerah kritis

Karena nilai mean dan std populasi diketahui maka uji statistik yang sesuai adalah dengan mengambil nilai $z = \frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}}$.

Karena $H_1 : \mu_{pH} > 7$ maka daerah kritisnya adalah $z > z_\alpha$, $z > 1.645$ Perhitungan nilai z_α dapat dilihat pada kode dibawah ini.

In [ ]:
```
z_a = st.norm.ppf(.95)
print("z_a = ",z_a)
```

```
z_a =  1.6448536269514722
```

Langkah 5 : Perhitungan uji statistik dan p-value

Berdasarkan statistik yang didapat pada jawaban nomor 1, didapatkan nilai σ, $\bar{x}$, n. Nilai p-value dihitung berdasarkan nilai uji statistik z.

$$z = \frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}}, \ \bar{x} = 7.08719, \ \sigma = 1.57280, \ n = 2010$$

$$z = \frac{7.08719-7}{1.57280/\sqrt{2010}} = 2.485$$

Perhitungan nilai z dan p-value dapat dilihat pada cuplikan kode dibawah ini :

In [ ]:
```
# Menghitung nilai rata-rata, std, m_0, dan n
mu_0 = 7
mean = df["pH"].mean()
std = df["pH"].std()
n = len(df["pH"])
print("xbar =", mean, ", std =", std, ", n =", n, ", mu_0 =", mu_0)

# Menghitung nilai z
z = (mean - mu_0)/(std/(n**0.5))
print("z =",z)

# Menghitung p-value
p = st.norm.sf(abs(z))
print("p-value =", p)
```

```
xbar = 7.0871927687138285 , std = 1.5728029470456655 , n = 2010 , mu_0 = 7
z = 2.485445147379887
p-value = 0.006469476288896462
```

Langkah 6 : Pengambilan keputusan

H_0 ditolak jika nilai uji terletak di daerah kritis, dan jika p-value < α (0.05).

Karena p-value yang didapat lebih kecil dari α (0.006469 < 0.05) dan berada di dalam daerah kritis $z > 1.645$, dengan nilai $z = 2.485$, maka diambil keputusan hipotesis nol ($H_0 : \mu = 7$) **ditolak**. Nilai rata-rata pH lebih dari 7.

---

b. Nilai Rata-rata Hardness tidak sama dengan 205?

In [ ]:
```
ax = df.boxplot(["Hardness"])
ax.set_title("Boxplot Hardness")
plt.show()
```

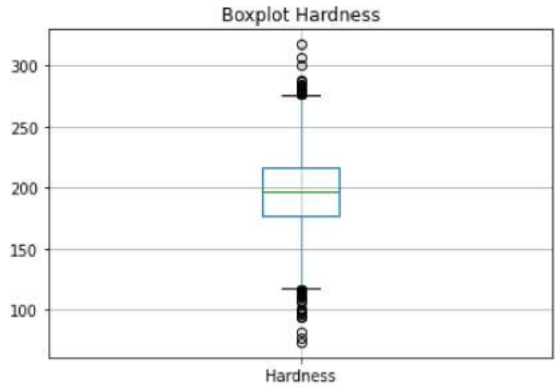

Langkah 1 : Menentukan hipotesis nol H_0

$H_0 : \mu_{Hardness} = 205$

Hipotesis nol yaitu nilai rata-rata Hardness sama dengan 205

Langkah 2 : Menentukan hipotesis alternatif H_1

$H_1 : \mu_{Hardness} \neq 205$

Hipotesis alternatif yaitu nilai rata-rata Hardness tidak sama dengan 205

Langkah 3 : Menentukan tingkat signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4 : Penentuan uji statistik dan daerah kritis

Dengan mengasumsikan kolom data Hardness mengikuti distribusi normal, penentuan daerah kritis dapat dilihat dari tabel distribusi normal. Karena nilai mean dan std populasi diketahui, maka penentuan uji statistik dilakukan dengan mengambil nilai z

$z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$

Serta karena $H_1 : \mu_{Hardness} \neq 205$, maka daerah kritisnya terletak pada $z > z_{a/2}$ atau $z < -z_{a/2}$, yaitu pada $z > 1.96$ atau $z < -1.96$. Perhitungan nilai $z_{a/2}$ dapat dilihat dari kode dibawah ini.

In [ ]:
```
z_adiv2 = st.norm.ppf(.975)
print("z_a/2 =",z_adiv2)
```

```
z_a/2 = 1.959963984540054
```

Langkah 5 : Perhitungan uji statistik dan p-value

Berdasarkan statistik yang didapat pada jawaban nomor 1, didapatkan nilai σ, $\bar{x}$, n. Nilai p-value dihitung berdasarkan nilai uji statistik z.

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}},\ \bar{x} = 195.96920,\ \sigma = 32.64317,\ n = 2010$$

$$z = \frac{7.08719 - 205}{1.57280/\sqrt{2010}} = -12.403137170010732$$

Perhitungan nilai z dan p-value dapat dilihat pada cuplikan kode dibawah ini :

In [ ]:
```
# Menghitung nilai rata-rata, std, m_0, dan n
mu_0 = 205
mean = df["Hardness"].mean()
std = df["Hardness"].std()
n = len(df["Hardness"])
print("xbar =", mean, ", std =", std, ", n =", n, ", mu_0 =", mu_0)

# Menghitung nilai z
z = (mean - mu_0)/(std/(n**0.5))
print("z =",z)

# Menghitung p-value dengan two tailed test
p = st.norm.sf(abs(z))*2
print("p-value =", p)
```

```
xbar = 195.96920903783524 , std = 32.643165859429864 , n = 2010 , mu_0 = 205
z = -12.403137170010732
p-value = 2.5128904895144654e-35
```

Langkah 6 : Pengambilan keputusan

H_0 ditolak jika p-value lebih kecil dari nilai signifikan α atau terletak di daerah kritis.

Karena p-value yang didapat lebih kecil dari alpha (2.5128904895144654e-35 < 0.05), dan nilai z = -12.4 berada di dalam daerah kritis $z < -z_{a/2}$, maka diambil keputusan hipotesis nol ($H_0 : \mu_{Hardness} = 205$) **ditolak**. Nilai rata-rata data pada kolom hardness tidak sama dengan 205.

---

c. Nilai Rata-rata 100 baris pertama kolom Solids bukan 21900?

In [ ]:
```
ax = df.loc[:99].boxplot(["Solids"])
ax.set_title("Boxplot 100 baris pertama kolom Solids")
plt.show()
```

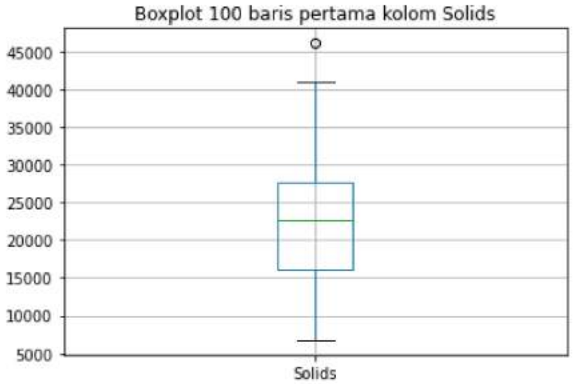

Langkah 1 : Menentukan hipotesis nol H_0

$H_0 : \mu_{100\ baris\ pertama\ kolom\ Solids} = 21900$

Hipotesis nol yaitu nilai rata-rata 100 baris pertama kolom Solids sama dengan 21900

Langkah 2 : Menentukan hipotesis alternatif H_1

$H_1 : \mu_{100\ baris\ pertama\ kolom\ Solids} \neq 21900$

Hipotesis alternatif yaitu nilai rata-rata 100 baris pertama kolom Solids tidak sama dengan 21900

Langkah 3 : Menentukan tingkat signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4 : Penentuan uji statistik dan daerah kritis

Karena nilai std populasi data pada kolom Solids tidak diketahui, maka penentuan uji statistik dilakukan dengan mengambil nilai $t = \frac{\bar{x}-\mu_0}{s/\sqrt{n}}$.

Daerah kritis nya terletak pada $t > t_{a/2}$ atau $t < -t_{a/2}$. Jadi $t > 1.66$ atau $t < -1.66$ .Perhitungan nilai $t_{a/2}$ dapat dilihat dari kode dibawah ini.

In [ ]:
```
# Derajat kebebasan = n - 1 = 100 - 1 = 99
v = 99
t_adiv2 = st.t.ppf(.95, v)
print("Derajat kebebasan =", v)
print("t_a/2 =",t_adiv2)
```

```
Derajat kebebasan = 99
t_a/2 = 1.6603911559963895
```

Langkah 5 : Perhitungan uji statistik dan p-value

Berdasarkan statistik yang didapat pada jawaban nomor 1, didapatkan nilai σ, $\bar{x}$, n. Nilai p-value dihitung berdasarkan nilai uji statistik z.

$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$, $\bar{x} = 22347.33445$, $s = 7935.9677$, $n = 100$

$t = \frac{22347.33445 - 21900}{7935.9677/\sqrt{100}} = 0.5637$

Perhitungan nilai z dan p-value dapat dilihat pada cuplikan kode dibawah ini :

In [ ]:
```
# Menghitung nilai rata-rata, std, m_0, dan n
mu_0 = 21900
mean = df["Solids"][:100].mean()
s = df["Solids"][:100].std()
n = 100
print("xbar =", mean, ", s =", s, ", n =", n, ", mu_0 =", mu_0)

# Menghitung nilai z
t = (mean - mu_0)/(s/(n**0.5))
print("t =",t)

# Menghitung p-value
v = 99
p = 2*(1-st.t.cdf(t, v))
print("p-value =", p)
```

```
xbar = 22347.334446383426 , s = 7935.967706199006 , n = 100 , mu_0 = 21900
t = 0.5636797715721551
p-value = 0.5742467134052605
```

Langkah 6 : Pengambilan keputusan

Karena p-value yang didapat lebih besar dari α (0.574 > 0.05), dan nilai t = 0.564 tidak berada di daerah kritis $t > 1.66$ atau $t < -1.66$ maka diambil keputusan hipotesis nol ($H_0 : \mu_{100\ baris\ pertama\ kolom\ Solids} = 21900$) **diterima**. Nilai rata-rata 100 baris pertama kolom Solids bernilai 21900.

---

d. Proporsi nilai Conductivity yang lebih dari 450, adalah tidak sama dengan 10%?

In [ ]:
```
ax = df.boxplot(["Conductivity"])
ax.set_title("Boxplot Conductivity")
plt.show()
```

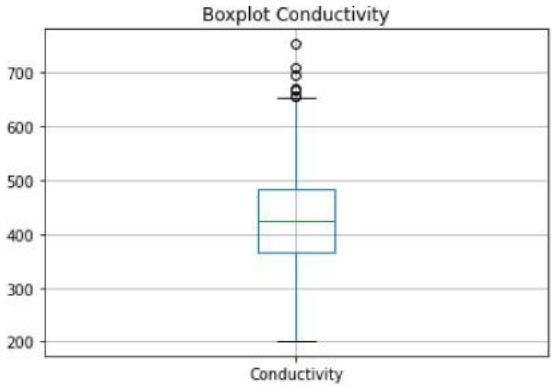

Langkah 1 : Menentukan hipotesis nol H_0

X = variabel random Conductivity.

$H_0 : P(X > 450) = 0.10$

Hipotesis nol yaitu proporsi nilai Conductivity yang lebih dari 450 sama dengan 10%

Langkah 2 : Menentukan hipotesis alternatif H_1

$H_1 : P(X > 450) \neq 0.10$

Hipotesis alternatif yaitu proporsi nilai Conductivity yang lebih dari 450 tidak sama dengan 10%

Langkah 3 : Menentukan tingkat signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4 : Penentuan uji statistik dan daerah kritis

Karena nilai mean dan std populasi diketahui, maka penentuan uji statistik dapat dilakukan dengan mengambil nilai

$z = \frac{x - (n \times p_0)}{\sqrt{p_0 \times q_0 \times n}}$.

Karena H_1 adalah $P(X > 450) \neq 0.10$, maka daerah kritisnya terletak pada $z > z_{a/2}$ atau $z < -z_{a/2}$, $z > 1.96$ atau $z < -1.96$.

Daerah kritisnya adalah $z > 1.96$ atau $z < -1.96$. Perhitungan nilai $z_{a/2}$ dapat diilihat pada kode dibawah ini.

In [ ]:
```
# Menghitung nilai Z_a/2
z_adiv2 = st.norm.ppf(.975)
print("z_a/2 =",z_adiv2)
```

```
z_a/2 = 1.959963984540054
```

Langkah 5 : Perhitungan uji statistik dan p-value

Perhitungan uji statistik dan p-value dapat dilihat pada kode dibawah ini.

```
In [ ]: # Mencari nilai p0, q0, dan x dari data Conductivity yang niainya lebih besar dari 450
x = 0
n = len(df["Conductivity"])
for i in range (n):
    if(df["Conductivity"][i] > 450):
        x += 1
p0 = 0.10
q0 = 1 - p0
print("x =", x, ", p0 =", p0, ", q0 =", q0)

# Menghitung nilai Z
z = (x - n*p0)/((n*p0*q0)**0.5)
print("z =",z)

# Menghitung nilai p value dengan two-tailed test
p = st.norm.sf(abs(z))*2
print("p-value =", p)
```

```
x = 745 , p0 = 0.1 , q0 = 0.9
z = 40.446376131589325
p-value = 0.0
```

Langkah 6 : Pengambilan keputusan

H_0 ditolak jika nilai uji terletak di daerah kritis, atau jika p-value < α (0.05).

Karena p-value yang didapat lebih kecil dari α (0 < 0.05) dan nilai z = 40.45 berada di dalam daerah kritis $z > 1.96$ atau $z < -1.96$, maka diambil keputusan hipotesis nol ($H_0 : P(X > 450) = 0.10$) **ditolak**. Proporsi nilai Conductivity yang lebih dari 450, tidak sama dengan 10%.

e. Proporsi nilai Trihalomethanes yang kurang dari 40, adalah kurang dari 5%?

```
In [ ]: ax = df.boxplot(["Trihalomethanes"])
ax.set_title("Boxplot Trihalomethanes")
plt.show()
```

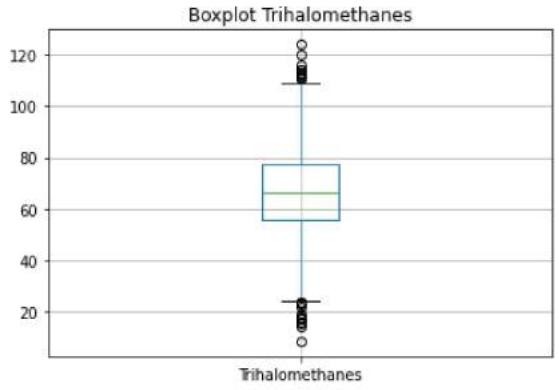

Langkah 1 : Menentukan hipotesis nol H_0

X = variabel random Trihalomethanes.

$H_0 : P(X < 40) = 0.05$

Hipotesis nol yaitu proporsi nilai Trihalomethanes yang kurang dari 40 adalah 5%

Langkah 2 : Menentukan hipotesis alternatif H_1

$H_1 : P(X < 40) < 0.05$

Hipotesis nol yaitu proporsi nilai Trihalomethanes yang kurang dari 40 adalah kurang dari 5%

Langkah 3 : Menentukan tingkat signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4 : Penentuan uji statistik dan daerah kritis

Karena nilai mean dan std populasi diketahui, maka penentuan uji statistik dapat dilakukan dengan mengambil nilai

$z = \frac{x-(n \times p_0)}{\sqrt{p_0 \times q_0 \times n}}$.

Karena H_1 adalah $H_1 : P < 0.05$, maka daerah kritisnya terletak pada $z < -z_{a/2}$, $z < -1.64$ Perhitungan nilai $z_{a/2}$ dapat dilihat pada kode dibawah ini.

In [ ]:
```
# Menghitung nilai Z_a
z_a = st.norm.ppf(.95)
print("z_a =",z_a)
```

```
z_a = 1.6448536269514722
```

Langkah 5 : Perhitungan uji statistik dan p-value

Perhitungan uji statistik dan p-value dapat dilihat pada kode dibawah ini.

In [ ]:
```
# Menghitung x, p0, dan q0 untuk data Trihalomethanes
x = 0
n = len(df["Trihalomethanes"])
for i in range (n):
    if(df["Trihalomethanes"][i] < 40):
        x += 1
p0 = 0.05
q0 = 1 - p0
print("x =", x, ", p0 =", p0, ", q0 =", q0)

# Menghitung nilai z
z = (x - n*p0)/((n*p0*q0)**0.5)
print("z =",z)

# Menghitung p value dengan one-tailed test
p = st.norm.sf(abs(z))
print("p-value =", p)
```

```
x = 106 , p0 = 0.05 , q0 = 0.95
z = 0.5628826416670959
p-value = 0.2867574004907627
```

Langkah 6 : Pengambilan keputusan

Karena nilai p value yang didapatkan lebih besar dari α, dimana 0.287 > 0.05 dan nilai z = 0.563 tidak terletak di dalam daerah kritis $z > 1.64$ atau $z < -1.64$, maka diambil keputusan hipotesis nol ($H_0 : P(X < 40) = 0.05$) **diterima**. Proporsi nilai Trihalomethanes yang kurang dari 40 adalah 5%

Nomor 5

Melakukan test hipotesis 2 sampel, dengan menuliskan 6 langkah testing dan menampilkan juga boxplotnya untuk kolom/bagian yang bersesuaian.

a. Data kolom Sulfate dibagi 2 sama rata: bagian awal dan bagian akhir kolom. Benarkah rata-rata kedua bagian tersebut sama?

A_1: Data bagian awal kolom Sulfate

A_2: Data bagian akhir kolom Sulfate

Berikut merupakan Boxplot dari A1 dan A2

In [ ]:
```
ax = df.loc[:1005].boxplot(["Sulfate"])
ax.set_title("Boxplot Sulfate bagian awal")
plt.show()

bx = df.loc[1005:].boxplot(["Sulfate"])
bx.set_title("Boxplot Sulfate bagian akhir")
plt.show()
```

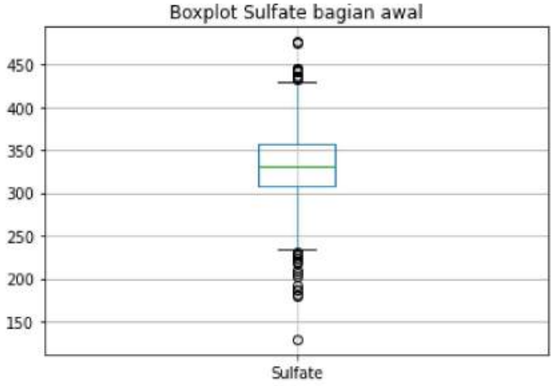

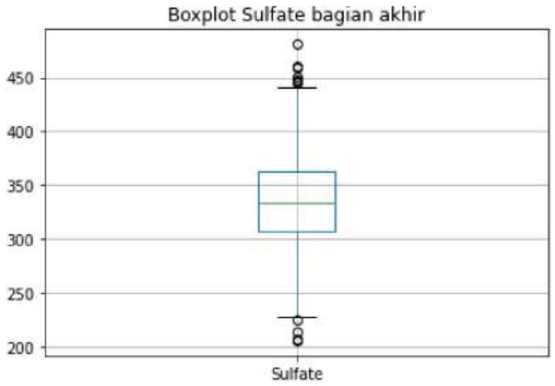

Langkah 1: Menentukan hipotesis nol H_0

H_0: $\mu_{A_1} = \mu_{A_2}$

Hipotesis nol yaitu rata-rata bagian awal kolom Sulfate sama dengan rata-rata bagian akhir kolom Sulfate.

Langkah 2: Menentukan hipotesis alternatif H_1

H_1: $\mu_{A_1} \neq \mu_{A_2}$

Hipotesis alternatif yaitu rata-rata bagian awal kolom Sulfate tidak sama dengan rata-rata bagian akhir kolom Sulfate yang artinya rata-rata A_1 dapat lebih besar atau lebih kecil dari rata-rata A_2 (two-tailed test).

Langkah 3: Menentukan Tingkat Signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4: Menentukan tes/uji statistik dengan menggunakan t-distribution dan mencari daerah kritis.

Daerah kritisnya dapat ditentukan dengan:

$$t < -t_{\alpha/2}(v) \quad or \quad t > t_{\alpha/2}(v)$$

$n_{A_1} = 1005, n_{A_2} = 1005$

Derajat kebebasan $(v) = v_{A_1} + v_{A_2} = (n_{A_1} - 1) + (n_{A_2} - 1) = n_{A_1} + n_{A_2} - 2$

$v = 1005 + 1005 - 2 = 2008$

In [ ]:
```
batas = t.ppf(0.025, 2008) # 0.025 berasal dari nilai alfa / 2
batas_bawah = round(batas, 5)
batas_atas = round(-batas, 5)

display(Markdown(("#### Daerah kritis adalah t < " + str(batas_bawah) + " atau t > " + str(batas_atas))))
```

Daerah kritis adalah t < -1.96115 atau t > 1.96115

Langkah 5: Menentukan nilai uji statistik dan p-value

Nilai t dapat ditentukan dengan menggunakan rumus:

Nilai t harus berada di luar daerah kritis supaya H_0 diterima. Rumus t diberikan sebagai berikut:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

$\bar{X}_1$: rata-rata sampel A_1, $\bar{X}_2$: rata-rata sampel A_2

μ_1 : rata-rata populasi A_1, μ_2 : rata-rata populasi A_2

S_1^2 : variansi sampel A_1, S_2^2 : variansi sampel A_2

Karena dari H_0, $\mu_{A_1} = \mu_{A_2}$ maka $\mu_{A_1} - \mu_{A_2} = 0$.

In [ ]:
```
x1 = df.loc[:1005, "Sulfate"].mean()
x2 = df.loc[1005:, "Sulfate"].mean()
s1 = df.loc[:1005, "Sulfate"].var()
s2 = df.loc[1005:, "Sulfate"].var()

t_val = ((x1 - x2) - 0 )/ sqrt((s1/1005) + (s2/1005))
p_val= 1 - t.cdf(t_val, 2008)

display(Markdown("### Nilai t adalah " + str(round(t_val, 5))))
display(Markdown("### Nilai p-value adalah " + str(round(p_val, 5))))
```

Nilai t adalah -2.0556

Nilai p-value adalah 0.98003

Langkah 6: Pengambilan keputusan

Keputusan diambil dengan membandingkan nilai t berada di luar atau dalam daerah kritis. Agar H_0 diterima, nilai t harus berada di luar daerah kritis.

Dari perhitungan didapat bahwa $t = -2.0556$, $t < -1.96115$ (berada di dalam daerah kritis) sehingga kesimpulannya adalah **H0 ditolak** dan **H1 diterima** yaitu rata-rata data bagian awal kolom Sulfate tidak sama dengan rata-rata data bagian akhir kolom Sulfate

b. Data kolom OrganicCarbon dibagi 2 sama rata: bagian awal dan bagian akhir kolom. Benarkah rata-rata bagian awal lebih besar dari pada bagian akhir sebesar 0.15?

A_1: Data bagian awal kolom OrganicCarbon

A_2: Data bagian akhir kolom OrganicCarbon

Berikut merupakan Boxplot dari A1 dan A2

In [ ]:
```
ax = df.loc[:1005].boxplot(["OrganicCarbon"])
ax.set_title("Boxplot OrganicCarbon bagian awal")
plt.show()

bx = df.loc[1005:].boxplot(["OrganicCarbon"])
bx.set_title("Boxplot OrganicCarbon bagian akhir")
plt.show()
```

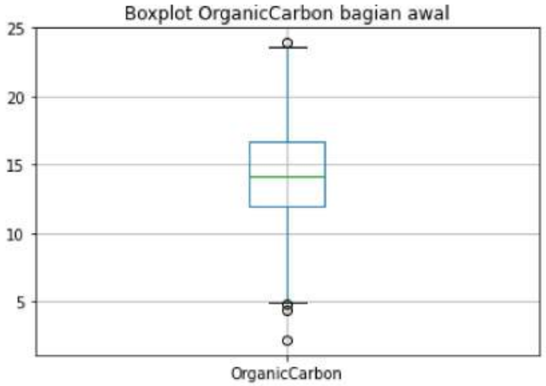

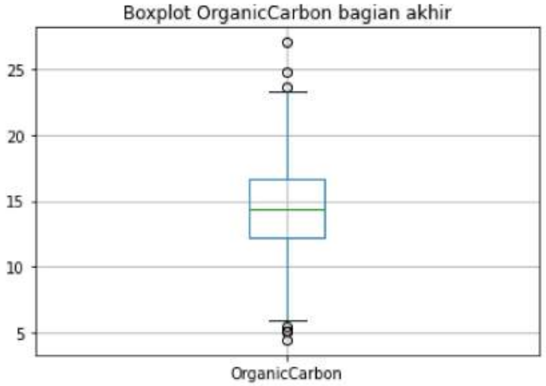

Langkah 1: Menentukan hipotesis nol H_0

H_0: $\mu_{A_1} = (\mu_{A_2} + 0.15)$

Hipotesis nol yaitu rata-rata data bagian awal kolom OrganicCarbon sama dengan rata-rata data bagian akhir kolom OrganicCarbon ditambah 0.15.

Langkah 2: Menentukan hipotesis alternatif H_1

H_1: $\mu_{A_1} \neq (\mu_{A_2} + 0.15)$

Hipotesis alternatif yaitu rata-rata data bagian awal kolom OrganicCarbon tidak sama dengan rata-rata data bagian akhir kolom OrganicCarbon ditambah 0.15 yang artinya rata-rata A_1 dapat lebih besar atau lebih kecil dari rata-rata A_2 ditambah 0.15 (two-tailed test)

Langkah 3: Menentukan Tingkat Signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4: Menentukan tes/uji statistik dengan menggunakan t-distribution dan mencari daerah kritis.

Daerah kritisnya dapat ditentukan dengan

$$t < -t_{\alpha/2}(v) \quad or \quad t > t_{\alpha/2}(v)$$

$v =$ derajat kebebasan $= n_{A_1} + n_{A_2} - 2$

$n_{A_1} = 1005, n_{A_2} = 1005$

Derajat kebebasan $(v) = v_{A_1} + v_{A_2} = (n_{A_1} - 1) + (n_{A_2} - 1) = n_{A_1} + n_{A_2} - 2$

$v = 1005 + 1005 - 2 = 2008$

In [ ]:
```
batas = t.ppf(0.025, 2008) # 0.025 berasal dari nilai alfa / 2
batas_bawah = round(batas, 5)
batas_atas = round(-batas, 5)

display(Markdown(("#### Daerah kritis adalah t < " + str(batas_bawah) + " atau t > " + str(batas_atas))))
```

Daerah kritis adalah t < -1.96115 atau t > 1.96115

Langkah 5: Menentukan nilai uji statistik dan p-value

Nilai t dapat ditentukan dengan menggunakan rumus:

Nilai t harus berada di luar daerah kritis supaya H_0 diterima. Rumus t diberikan sebagai berikut:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

$\bar{X}_1$: rata-rata sampel A_1, $\bar{X}_2$: rata-rata sampel A_2

μ_1 : rata-rata populasi A_1, μ_2 : rata-rata populasi A_2

S_1^2 : variansi sampel A_1, S_2^2 : variansi sampel A_2

Karena dari H_0, $\mu_{A_1} = \mu_{A_2} + 0.15$ maka $\mu_{A_1} - \mu_{A_2} = 0.15$.

In [ ]:
```
x1 = df.loc[:1005, "OrganicCarbon"].mean() #masihragu
x2 = df.loc[1005:, "OrganicCarbon"].mean()
s1 = df.loc[:1005, "OrganicCarbon"].var()
s2 = df.loc[1005:, "OrganicCarbon"].var()

t_val = ((x1 - x2) - 0.15) / sqrt((s1/1005) + (s2/1005))
p_val= 1 - t.cdf(t_val, 2008)
```

```
display(Markdown("### Nilai t adalah " + str(round(t_val, 5))))
display(Markdown("### Nilai p-value adalah " + str(round(p_val, 5))))
```

Nilai t adalah -2.42486

Nilai p-value adalah 0.9923

Langkah 6: Pengambilan keputusan

Keputusan diambil dengan membandingkan nilai t berada di luar atau dalam daerah kritis. Agar H_0 diterima, nilai t harus berada di luar daerah kritis.

Dari perhitungan didapat bahwa $t = -2.42486, t < -1.96115$ (berada di dalam daerah kritis) sehingga kesimpulannya adalah **H0 ditolak** dan **H1 diterima** yaitu rata-rata data bagian awal kolom OrganicCarbon tidak sama dengan rata-rata data bagian akhir kolom OrganicCarbon ditambah 0.15

c. Rata-rata 100 baris pertama kolom Chloramines sama dengan 100 baris terakhirnya?

A_1: Data 100 baris pertama kolom Chloramines

A_2: Data 100 baris terakhir kolom Chloramines

Berikut merupakan Boxplot dari A1 dan A2

In [ ]:
```
ax = df.loc[:100].boxplot(["Chloramines"])
ax.set_title("Boxplot A1")
plt.show()

bx = df.loc[1910:].boxplot(["Chloramines"])
bx.set_title("Boxplot A2")
plt.show()
```

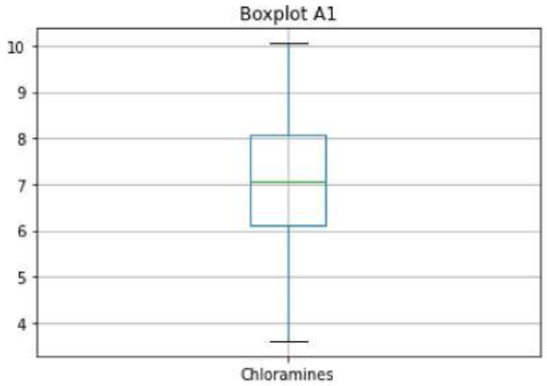

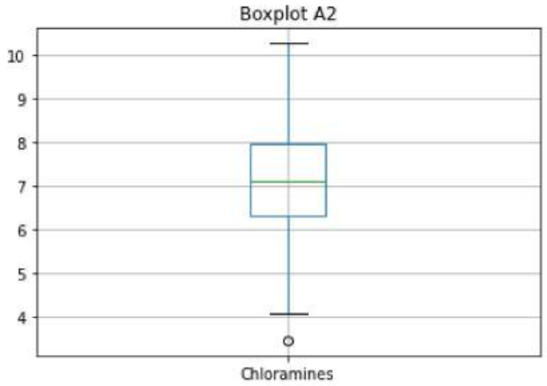

Langkah 1: Menentukan hipotesis nol H_0

H_0: $\mu_{A_1} = \mu_{A_2}$

Hipotesis nol yaitu rata-rata 100 baris pertama kolom Chloramines sama dengan rata-rata 100 baris terakhir kolom Chloramines.

Langkah 2: Menentukan hipotesis alternatif H_1

H_1: $\mu_{A_1} \neq \mu_{A_2}$

Hipotesis alternatif yaitu rata-rata 100 baris pertama kolom Chloramines tidak sama dengan rata-rata 100 baris terakhir kolom Chloramines yang artinya rata-rata A_1 dapat lebih besar atau lebih kecil dari rata-rata A_2 (two-tailed test).

Langkah 3: Menentukan Tingkat Signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4: Menentukan tes/uji statistik dengan menggunakan t-distribution dan mencari daerah kritis.

Daerah kritisnya dapat ditentukan dengan:

$$t < -t_{\alpha/2}(v) \quad or \quad t > t_{\alpha/2}(v)$$

$n_{A_1} = 100, n_{A_2} = 100$

Derajat kebebasan $(v) = v_{A_1} + v_{A_2} = (n_{A_1} - 1) + (n_{A_2} - 1) = n_{A_1} + n_{A_2} - 2$

$v = 100 + 100 - 2 = 198$

In [ ]:
```
batas = t.ppf(0.025, 198) # 0.025 berasal dari nilai alfa / 2
batas_bawah = round(batas, 5)
batas_atas = round(-batas, 5)

display(Markdown(("#### Daerah kritis adalah t < " + str(batas_bawah) + " atau t > " + str(batas_atas))))
```

Daerah kritis adalah t < -1.97202 atau t > 1.97202

Langkah 5: Menentukan nilai uji statistik dan p-value

Nilai t dapat ditentukan dengan menggunakan rumus:

Nilai t harus berada di luar daerah kritis supaya H_0 diterima. Rumus t diberikan sebagai berikut:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

$\bar{X}_1$: rata-rata sampel A_1, $\bar{X}_2$: rata-rata sampel A_2

μ_1 : rata-rata populasi A_1, μ_2 : rata-rata populasi A_2

S_1^2 : variansi sampel A_1, S_2^2 : variansi sampel A_2

Karena dari H_0, $\mu_{A_1} = \mu_{A_2}$ maka $\mu_{A_1} - \mu_{A_2} = 0$.

In [ ]:
```
x1 = df.loc[:100, "Chloramines"].mean()
x2 = df.loc[1910:, "Chloramines"].mean()
s1 = df.loc[:100, "Chloramines"].var()
s2 = df.loc[1910:, "Chloramines"].var()

t_val = ((x1 - x2) - 0)/ sqrt((s1/100) + (s2/100))
p_val = 1 - t.cdf(t_val, 198)

display(Markdown("### Nilai t adalah " + str(round(t_val, 5))))
display(Markdown("### Nilai p-value adalah " + str(round(p_val, 5))))
```

Nilai t adalah -0.70998

Nilai p-value adalah 0.76072

Langkah 6: Pengambilan keputusan

Keputusan diambil dengan membandingkan nilai t berada di luar atau dalam daerah kritis. Agar H_0 diterima, nilai t harus berada di luar daerah kritis.

Dari perhitungan didapat bahwa $t = -0.70999$, $t > -1.97202$ dan $t < 1.97202$ (berada di luar daerah kritis) sehingga kesimpulannya adalah **H0 diterima** yaitu rata-rata 100 baris pertama kolom Chloramines sama dengan rata-rata 100 baris terakhirnya.

d. Proporsi nilai bagian awal Turbidity yang lebih dari 4, adalah lebih besar daripada, proporsi nilai yang sama di bagian akhir Turbidity ?

A_1: Data bagian awal kolom Turbidity

A_2: Data bagian akhir kolom Turbidity

Berikut merupakan Boxplot dari A1 dan A2

```
In [ ]: ax = df.loc[:1005].boxplot(["Turbidity"])
        ax.set_title("Boxplot Turbidity bagian awal")
        plt.show()

        bx = df.loc[1005:].boxplot(["Turbidity"])
        bx.set_title("Boxplot Turbidity bagian akhir")
        plt.show()
```

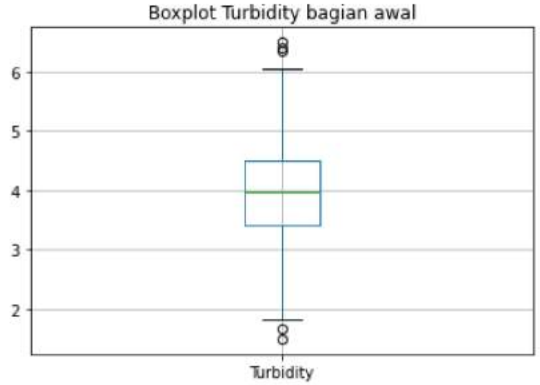

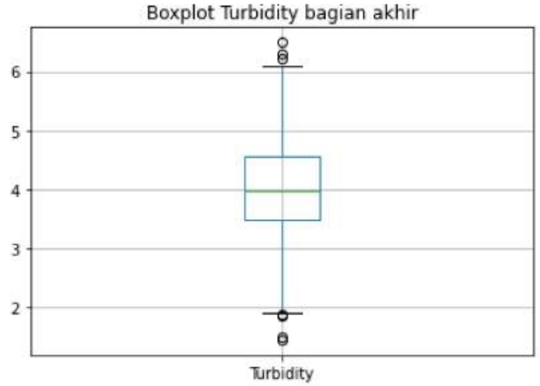

Langkah 1: Menentukan hipotesis nol H_0

H_0: $P(A_1 > 4) = P(A_2 > 4)$

Hipotesis nol yaitu proporsi nilai data bagian awal kolom Turbidity yang bernilai lebih dari 4 sama dengan proporsi nilai data bagian akhir kolom Turbidity yang bernilai lebih dari 4

Langkah 2: Menentukan hipotesis alternatif H_1

H_1: $P(A_1 > 4) > P(A_2 > 4)$

Hipotesis alternatif yaitu proporsi nilai data bagian awal kolom Turbidity yang bernilai lebih dari 4 lebih besar dari proporsi nilai data bagian akhir kolom Turbidity yang bernilai lebih dari 4 (one-tailed test).

Langkah 3: Menentukan Tingkat Signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4: Menentukan tes/uji statistik dengan menggunakan Z-test dengan normal distribution dan mencari daerah kritis.

Daerah kritisnya dapat ditentukan dengan:

$$z > z_\alpha$$

In [ ]:
```
z_val = round(norm.ppf(0.95), 5)

display(Markdown(("#### Daerah kritis adalah z > " + str(z_val) )))
```

Daerah kritis adalah z > 1.64485

Langkah 5: Menentukan nilai uji statistik dan p-value

Nilai z dapat ditentukan dengan menggunakan rumus:

$$z = \frac{(\hat{p}_1 - \hat{p}_2)}{\sqrt{\hat{p}\hat{q}(\frac{1}{n_1} + \frac{1}{n_2})}}$$

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$$

$\hat{p}_1$: proporsi sampel A_1, $\hat{p}_2$: proporsi sampel A_2

$\hat{p}$: proporsi kedua sampel

x_1 : jumlah data A_1 dengan nilai lebih dari 4, x_2 : jumlah data A_2 dengan nilai lebih dari 4

n_1 : jumlah keseluruhan data A_1, n_2 : jumlah keseluruhan data A_2

In [ ]:
```
a1 = df.loc[:1005, "Turbidity"]
a2 = df.loc[1005:, "Turbidity"]

def count(a):
    count = 0
    for data in a:
        if (data > 4):
            count += 1
    return count

x1 = count(a1)
x2 = count(a2)

# n1 = 1005
# n2 = 1005

p1 = x1 / 1005
p2 = x2 / 1005
p = (x1 + x2) / 2010
```

```
q = 1 - p
z_val = (p1 - p2) / sqrt(p * q * (1/1005 + 1/1005))
p_val = 1 - norm.cdf(z_val)

display(Markdown("### Nilai z adalah " + str(round(z_val, 5))))
display(Markdown("### Nilai p-value adalah " + str(round(p_val, 5))))
```

Nilai z adalah -0.13389

Nilai p-value adalah 0.55326

Langkah 6: Pengambilan keputusan

Keputusan diambil dengan membandingkan nilai z berada di luar atau dalam daerah kritis. Agar H_0 diterima, nilai z harus berada di luar daerah kritis.

Dari perhitungan didapat bahwa $z = -0.13389$, $z < 1.64485$ (berada di luar daerah kritis) sehingga kesimpulannya adalah **H0 diterima** yaitu proporsi nilai data bagian awal kolom Turbidity yang bernilai lebih dari 4 sama dengan proporsi nilai data bagian akhir kolom Turbidity yang bernilai lebih dari 4 yang artinya pernyataan bahwa proporsi nilai bagian awal kolom Turbidity yang lebih dari 4 adalah lebih besar daripada proporsi nilai yang sama di bagian akhir Turbidity adalah salah.

e. Bagian awal kolom Sulfate memiliki variansi yang sama dengan bagian akhirnya?

A_1: Data bagian awal kolom Sulfate

A_2: Data bagian akhir kolom Sulfate

Berikut merupakan Boxplot dari A1 dan A2

In [ ]:
```
ax = df.loc[:1005].boxplot(["Sulfate"])
ax.set_title("Boxplot Sulfate bagian awal")
plt.show()

bx = df.loc[1005:].boxplot(["Sulfate"])
bx.set_title("Boxplot Sulfate bagian akhir")
plt.show()
```

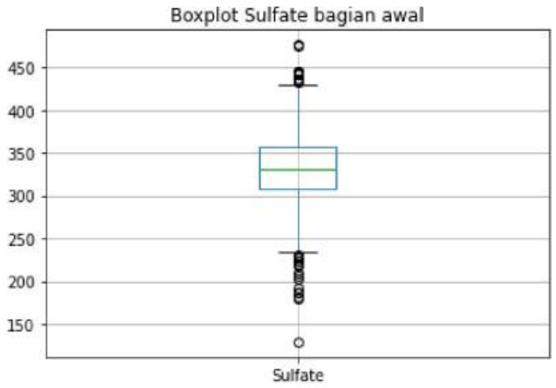

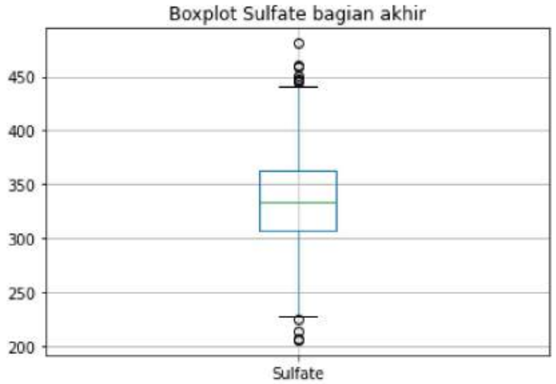

Langkah 1: Menentukan hipotesis nol H_0

H_0: $\sigma^2_{A_1} = \sigma^2_{A_2}$

Hipotesis nol yaitu variansi bagian awal kolom Sulfate sama dengan variansi bagian akhir kolom Sulfate.

Langkah 2: Menentukan hipotesis alternatif H_1

H_1: $\sigma^2_{A_1} = \sigma^2_{A_2}$

Hipotesis alternatif yaitu variansi bagian awal kolom Sulfate tidak sama dengan variansi bagian akhir kolom Sulfate yang artinya variansi A_1 dapat lebih besar atau lebih kecil dari variansi A_2 (two-tailed test).

Langkah 3: Menentukan Tingkat Signifikansi α

Tingkat signifikansi yang diambil adalah $\alpha = 0.05$

Langkah 4: Menentukan tes/uji statistik dengan menggunakan F-distribution dan mencari daerah kritis.

Daerah kritisnya dapat ditentukan dengan:

$$f < f_{1-\alpha/2}(v_1, v_2) \quad or \quad f > f_{\alpha/2}(v_1, v_2)$$

$n_{A_1} = 1005, n_{A_2} = 1005$

Derajat kebebasan A1 $(v_1) = n_{A_1} - 1 = 1005 - 1 = 1004$

Derajat kebebasan A2 $(v_2) = n_{A_2} - 1 = 1005 - 1 = 1004$

In [ ]:
```
batas_atas = round(f.ppf(1-0.025, 1004, 1004), 5) # 0.025 berasal dari nilai alfa / 2
batas_bawah = round(f.ppf(0.025, 1004, 1004), 5) # 0.025 berasal dari nilai alfa / 2

display(Markdown(("#### Daerah kritis adalah f < " + str(batas_bawah) + " atau f > " + str(batas_atas))))
```

Daerah kritis adalah f < 0.88357 atau f > 1.13177

Langkah 5: Menentukan nilai uji statistik dan p-value

Nilai f dapat ditentukan dengan menggunakan rumus:

$$f = \frac{\sigma^2_{A_1}}{\sigma^2_{A_2}}$$

$\sigma^2_{A_1}$: variansi sampel A_1, $\sigma^2_{A_2}$: variansi sampel A_2

In [ ]:
```
s1 = df.loc[:1005, "Sulfate"].var()
s2 = df.loc[1005:, "Sulfate"].var()

f_val = s1 / s2
p_val = f.cdf(f_val, 1004, 1004)

display(Markdown("### Nilai f adalah " + str(round(f_val, 5))))
display(Markdown("### Nilai p-value adalah " + str(round(p_val, 5))))
```

Nilai f adalah 1.01503

Nilai p-value adalah 0.5934

Langkah 6: Pengambilan keputusan

Keputusan diambil dengan membandingkan nilai f berada di luar atau dalam daerah kritis. Agar H_0 diterima, nilai f harus berada di luar daerah kritis.

Dari perhitungan didapat bahwa $f = 1.01503$, $f < 1.13177$ (berada di luar daerah kritis) sehingga kesimpulannya adalah **H0 diterima** yaitu variansi data bagian awal kolom Sulfate sama dengan variansi data bagian akhir kolom Sulfate

Nomor 6

Menentukan apakah setiap kolom non-target berkorelasi dengan kolom target dengan menggambarkan juga scatter plot nya. Gunakan correlation test.

Untuk menentukan korelasi antara dua kolom, digunakan koefisien korelasi Pearson dengan rumus:

$$r = \frac{\sigma_{xy}}{\sigma_x \sigma_y} = \frac{n\sum xy - (\sum x)(\sum y)}{\sqrt{(n\sum x^2 - (\sum x)^2)(n\sum y^2 - (\sum y)^2)}}$$

dengan X adalah kolom target dan Y adalah kolom non-target

Jika nilai koefisien korelasi:

- Bernilai 0, maka tidak ada korelasi antara X dan Y
- Bernilai 1, maka ada korelasi yang kuat antara X dan Y dan bernilai positif (berbanding lurus).
- Bernilai -1, maka ada korelasi yang kuat antara X dan Y tetapi bernilai negatif (berbanding terbalik).

Pedoman untuk memberikan interpretasi koefisien korelasi (Sugiyono, 2012: 257) adalah sebagai berikut:

- 0,00 – 0,199 = Korelasi sangat rendah
- 0,20 – 0,399 = Korelasi rendah
- 0,40 – 0,599 = Korelasi sedang
- 0,60 – 0,799 = Korelasi kuat
- 0,80 – 1,000 = Korelasi sangat kuat

pH

In [ ]:
```
sns.regplot(x = df["pH"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["pH"].corr(df["Potability"]))))
```

```
Koefisien korelasi: 0.01547509440843348
```

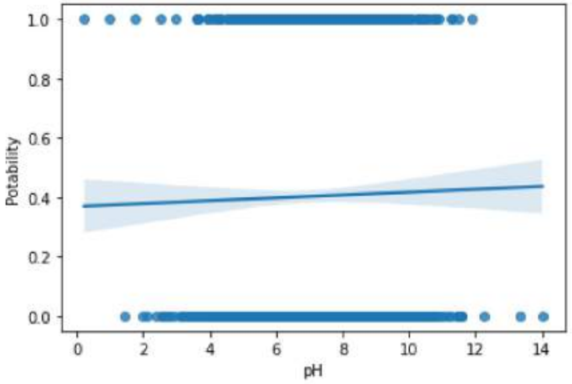

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara pH dan Potability bernilai positif (berbanding lurus) yaitu jika nilai pH meningkat maka nilai Potability juga meningkat. Hubungan korelasi antara pH dan Potability tergolong dalam kategori sangat rendah.

Hardness

In [ ]:
```
sns.regplot(x = df["Hardness"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["Hardness"].corr(df["Potability"]))))
```

```
Koefisien korelasi: -0.0014631528959479344
```

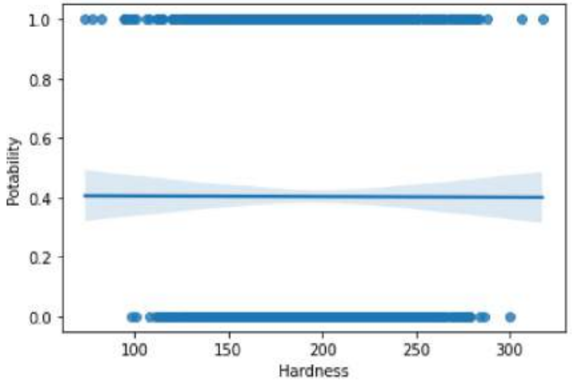

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara Hardness dan Potability bernilai negatif (berbanding terbalik) yaitu jika nilai Hardnesss meningkat maka nilai Potability menurun. Hubungan korelasi antara Hardness dan Potability tergolong dalam kategori sangat rendah.

Solids

In [ ]:
```
sns.regplot(x = df["Solids"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["Solids"].corr(df["Potability"]))))
```

```
Koefisien korelasi: 0.03897657818173466
```

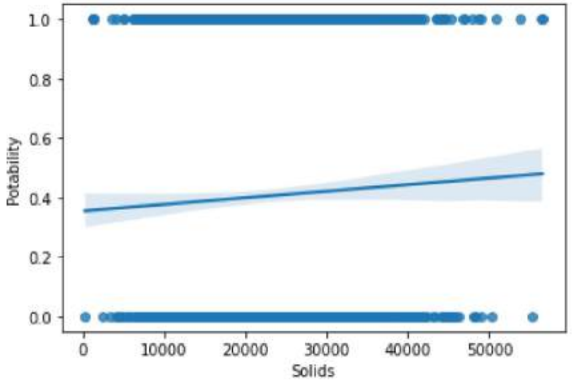

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara Solids dan Potability bernilai positif (berbanding lurus) yaitu jika nilai Solids meningkat maka nilai Potability juga meningkat. Hubungan korelasi antara Solids dan Potability tergolong dalam kategori sangat rendah.

Chloramines

In [ ]:
```
sns.regplot(x = df["Chloramines"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["Chloramines"].corr(df["Potability"]))))
```

```
Koefisien korelasi: 0.020778921840524O9
```

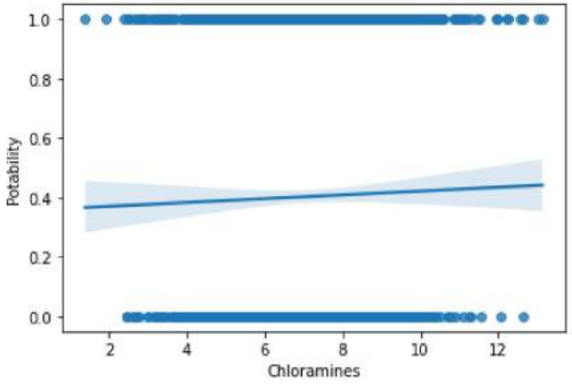

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara Chloramines dan Potability bernilai positif (berbanding lurus) yaitu jika nilai Chloramines meningkat maka nilai Potability juga meningkat. Hubungan korelasi antara Chloramines dan Potability tergolong dalam kategori sangat rendah.

Sulfate

In [ ]:
```
sns.regplot(x = df["Sulfate"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["Sulfate"].corr(df["Potability"]))))
```

```
Koefisien korelasi: -0.015703164419273778
```

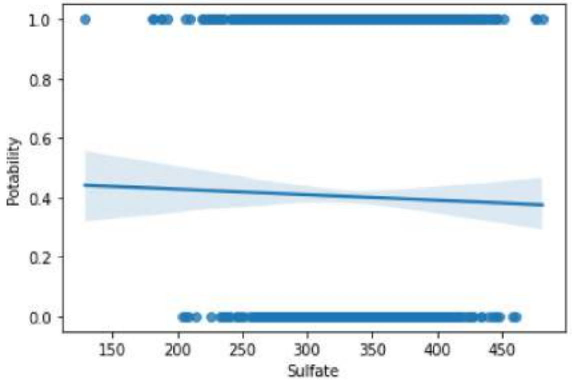

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara Sulfate dan Potability bernilai negatif (berbanding terbalik) yaitu jika nilai Sulfate meningkat maka nilai Potability menurun. Hubungan korelasi antara Sulfate dan Potability tergolong dalam kategori sangat rendah.

Conductivity

In [ ]:
```
sns.regplot(x = df["Conductivity"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["Conductivity"].corr(df["Potability"]))))
```

```
Koefisien korelasi: -0.016257120111377067
```

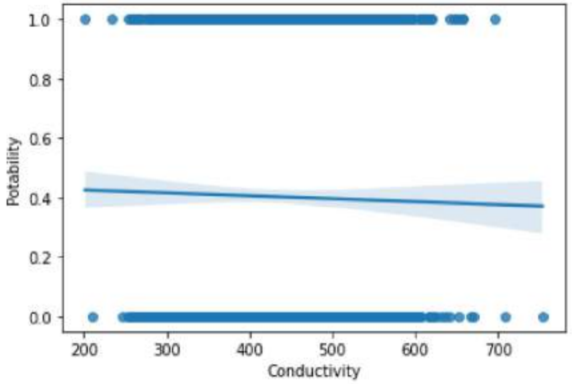

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara Conductivity dan Potability bernilai negatif (berbanding terbalik) yaitu jika nilai Chloramines meningkat maka nilai Potability menurun. Hubungan korelasi antara Chloramines dan Potability tergolong dalam kategori sangat rendah.

OrganicCarbon

In [ ]:
```
sns.regplot(x = df["OrganicCarbon"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["OrganicCarbon"].corr(df["Potability"]))))
```

```
Koefisien korelasi: -0.015488461910747259
```

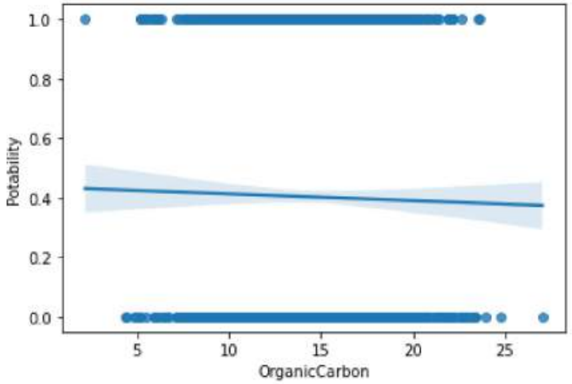

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara OrganicCarbon dan Potability bernilai negatif (berbanding terbalik) yaitu jika nilai OrganicCarbon meningkat maka nilai Potability menurun. Hubungan korelasi antara OrganicCarbon dan Potability tergolong dalam kategori sangat rendah.

Trihalomethanes

In [ ]:
```
sns.regplot(x = df["Trihalomethanes"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["Trihalomethanes"].corr(df["Potability"]))))
```

```
Koefisien korelasi: 0.009236711064712997
```

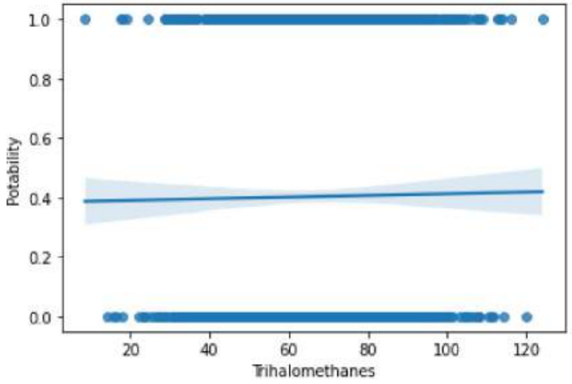

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara Trihalomethanes dan Potability bernilai positif (berbanding lurus) yaitu jika nilai Trihalomethanes meningkat maka nilai Potability juga meningkat. Hubungan korelasi antara Trihalomethanes dan Potability tergolong dalam kategori sangat rendah.

Turbidity

In [ ]:
```
sns.regplot(x = df["Turbidity"], y = df["Potability"])

print("Koefisien korelasi: " + str((df["Turbidity"].corr(df["Potability"]))))
```

```
Koefisien korelasi: 0.022331042640622665
```

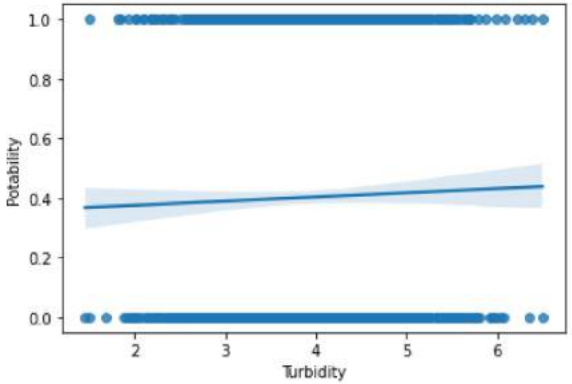

Dari koefisien korelasi yang didapatkan, dapat disimpulkan bahwa korelasi antara Turbidity dan Potability bernilai positif (berbanding lurus) yaitu jika nilai Turbidity meningkat maka nilai Potability juga meningkat. Hubungan korelasi antara Turbidity dan Potability tergolong dalam kategori sangat rendah.